

Lista 2 - MAE 0399 - Análise de Dados e Simulação

Guilherme Ventura (11340293), Milton Leal (8973974), Richard Sousa (11810898)

25/05/2021

Exercício 2:

Para as distribuições $N(2,1)$, $\text{Exp}(2)$, $U(1,3)$, faça 100 réplicas de amostras de tamanho $n = 5, 10$ e 50 e para cada réplica determine a média amostral. Apresente os histogramas das médias amostrais e compare as distribuições originais (desenhe as curvas das funções densidades de probabilidade).

R:

$N(2,1)$

```
set.seed(42)


#gera amostras de tamanhos 5, 10 e 50
normal_n5 = replicate(100, rnorm(5, 2,1))
normal_n10 = replicate(100, rnorm(10, 2,1))
normal_n50 = replicate(100, rnorm(50, 2,1))

#vetores com as médias das amostras
media_normal_n5 = c(colMeans(normal_n5))
media_normal_n10 = c(colMeans(normal_n10))
media_normal_n50 = c(colMeans(normal_n50))

#plota histograma dos dados simulados para amostra de tamanho 5
hist(media_normal_n5, probability = T,
     main = "Histograma de médias da N(2,1) de tamanho 5",
     ylab="Densidade",
     xlab="Reta Real")

#plota curva da função densidade
f = seq(-1,5, 0.001)
g = (1/sqrt(2*pi))*exp(-(1/2)*((f-2)^2)/2)
lines(f,g)
```


Histograma de médias da $N(2,1)$ de tamanho 5



```
#plota histograma dos dados simulados para amostra de tamanho 10
hist(media_normal_n10, probability = T,
     main = "Histograma de médias da N(2,1) de tamanho 10",
     ylab="Densidade",
     xlab="Reta Real")

f = seq(-1,5, 0.001)
g = (1/sqrt(2*pi))*exp(-(1/2)*((f-2)^2)/2)
lines(f,g)
```


Histograma de médias da $N(2,1)$ de tamanho 10



```
#plota histograma dos dados simulados para amostra de tamanho 50
hist(media_normal_n50, probability = T,
     main = "Histograma de médias da N(2,1) de tamanho 50",
     ylab="Densidade",
     xlab="Reta Real")

f = seq(-1,5, 0.001)
g = (1/sqrt(2*pi))*exp(-(1/2)*((f-2)^2)/2)
lines(f,g)
```

Histograma de médias da $N(2,1)$ de tamanho 50



EXP(2)


```
#gera amostras de tamanhos 5, 10 e 50
exp_n5 = replicate(100, rexp(5, 2))
exp_n10 = replicate(100, rexp(10, 2))
exp_n50 = replicate(100, rexp(50, 2))

#vetores com as médias das amostras
media_exp_n5 = c(colMeans(exp_n5))
media_exp_n10 = c(colMeans(exp_n10))
media_exp_n50 = c(colMeans(exp_n50))

#plota histograma dos dados simulados para amostra de tamanho 5
hist(media_exp_n5, probability = T,
     main = "Histograma de médias da Exp(2) de tamanho 5",
     ylab="Densidade",
     xlab="Reta Real")

#plota curva da função densidade
f = seq(0,5, 0.001)
g = 2*exp(-2*f)
lines(f,g)
```


Histograma de médias da Exp(2) de tamanho 5



```
#plota histograma dos dados simulados para amostra de tamanho 10
hist(media_exp_n10, probability = T,
     main = "Histograma de médias da Exp(2) de tamanho 10",
     ylab="Densidade",
     xlab="Reta Real")

f = seq(0,5, 0.001)
g = 2*exp(-2*f)
lines(f,g)
```


Histograma de médias da Exp(2) de tamanho 10



```
#plota histograma dos dados simulados para amostra de tamanho 50
hist(media_exp_n50, probability = T,
     main = "Histograma de médias da Exp(2) de tamanho 50",
     ylab="Densidade",
     xlab="Reta Real")

f = seq(0,5, 0.001)
g = 2*exp(-2*f)
lines(f,g)
```

Histograma de médias da Exp(2) de tamanho 50



U(1,3)


```
#gera amostras de tamanhos 5, 10 e 50
u_n5 = replicate(100, runif(5,1,3))
u_n10 = replicate(100, runif(10,1,3))
u_n50 = replicate(100, runif(50,1,3))

#vetores com as médias das amostras
media_u_n5 = c(colMeans(u_n5))
media_u_n10 = c(colMeans(u_n10))
media_u_n50 = c(colMeans(u_n50))

#plota histograma dos dados simulados para amostra de tamanho 5
hist(media_u_n5, probability = T,
     main = "Histograma de médias da U(3,1) de tamanho 5",
     ylab="Densidade",
     xlab="Reta Real", ylim = c(0,3))

#plota curva densidade
abline(h=1/2)
```


Histograma de médias da U(3,1) de tamanho 5



```
#plota histograma dos dados simulados para amostra de tamanho 10
hist(media_u_n10, probability = T,
      main = "Histograma de médias da U(3,1) de tamanho 10",
      ylab="Densidade",
      xlab="Reta Real")

abline(h=1/2)
```



Histograma de médias da U(3,1) de tamanho 10



```
#plota histograma dos dados simulados para amostra de tamanho 50
hist(media_u_n50, probability = T,
     main = "Histograma de médias da U(3,1) de tamanho 50",
     ylab="Densidade",
     xlab="Reta Real")

abline(h=1/2)
```

Histograma de médias da U(3,1) de tamanho 50



Exercício 6:

É possível provar que se somarmos números aleatórios básicos até que a soma exceda 1, então o número esperado dessa soma é a constante e . Isto é,

$$N = \min \left\{ n : \sum_{i=1}^n U_i > 1 \right\}$$

então $E[N] = e$.

a) Use este procedimento para estimar e . Faça 1000 simulações.

R:

```
set.seed(31415)

N <- c() #guarda quantidade de números básicos gerados por simulação

for (k in 1:1000){

  soma <- 0 #guarda a soma dos números básicos sorteados
  n <- 0 #conta a quantidade de números básicos gerados

  while (soma <= 1){ #verifica se a soma excedeu 1

    n <- n + 1 #acrescenta ao contador
    soma <- soma + runif(1) #acrescenta à soma e gera o número básico

  }

  N[k] <- n

}
```

```

    }
    N[k] <- n
  }
E <- mean(N) #média das quantidades de números básicos gerados
E

```

```
## [1] 2.717
```

O valor simulado nessa execução foi $E[N] = 2.717$.

b) Estime a variância do estimador usado em (a) e apresente o intervalo de 95 % de confiança para e .

R:

Para essas simulações obtivemos a seguinte variância amostral:

```

variancia <- var(N)
variancia

```

```
## [1] 0.6855966
```

Com \hat{e} sendo o estimador e s o desvio padrão amostral, o intervalo de confiança é dado por:

$$IC(\gamma; \hat{e}) = \left[\hat{e} - z_\gamma \frac{s}{\sqrt{n}}; \hat{e} + z_\gamma \frac{s}{\sqrt{n}} \right]$$

Com $\gamma = 95\%$ tem-se $z_\gamma = 1.96$

```

s <- sqrt(variancia) #calcula desvio padrão

inf <- E - 1.96 * s / sqrt(length(N)) #calcula limite inferior
sup <- E + 1.96 * s / sqrt(length(N)) #calcula limite superior

IC <- c(inf, sup)
IC

```

```
## [1] 2.66568 2.76832
```

Ou seja, com 95 de confiança, o intervalo aleatório entre 2.66568 e 2.76832 contém o verdadeiro valor de e .

Exercício 9:

Sejam X_1, \dots, X_n v.a. independentes e identicamente distribuídas com média μ . Para duas constantes tais que $a < b$, estamos interessados em estimar $p = P[a < \bar{X} - \mu < b]$.

a) Explique como usar o método de *bootstrap* para estimar p .

R:

Primeiramente, precisamos determinar a distribuição da variável aleatória $V = \bar{X} - \mu$.

Para isso, vamos considerar que \bar{X} é uma proxy para μ e lançaremos mão do método de *bootstrap* para gerar B reamostragens. Calculemos a média de cada uma dessas reamostras e as denotemos por \bar{X}_i^* .

Dessa forma, a distribuição estimada de V será um vetor de tamanho B composto pelas diferenças $\bar{X}_i^* - \bar{X}$ para $i \in (1, \dots, n)$.

Agora, se definirmos uma variável aleatória indicadora Y tal que para cada \bar{X}_i^* seja:

$$Y_i = \begin{cases} 1, & \text{se } a < \bar{X}_i^* < b \\ 0, & \text{caso contrário,} \end{cases}$$

então p pode ser estimado como:

$$\hat{p} = \frac{\sum_i^n Y_i}{B}.$$

b) Considere $n = 10, a = -5$ e $b = 5$. Estime p considerando que os valores observados são: 56, 101, 78, 67, 93, 87, 64, 72, 80 e 69.

R:

```
set.seed(32)

dados = c(56,101,78,67,93,87,64,72,80,69) #amostra de dados
a = 5 #limite superior
b = -5 #Limite inferior

media_dados = mean(dados)

amostras_boot = 1000 #número B de amostras de Bootstrap

#calcula a média de 1000 amostras de Bootstrap com reposição
medias_boot = replicate(amostras_boot, mean(sample(dados, 10, replace = TRUE)))

#distribuição da v.a. V
V = medias_boot - media_dados

#soma a quantidade de TRUEs que verificiam a confição e divide pelo total
p_hat = sum(V > -5 & V < 5)/amostras_boot

p_hat
```

```
## [1] 0.756
```